TÓM TẮT VÀ PHÂN TÍCH BÀI BÁO

U-Net: Convolutional Networks for Biomedical Image Segmentation

Olaf Ronneberger, Philipp Fischer, and Thomas Brox (2015)

MICCAI 2015 — LNCS 9351, pp. 234–241

1. Tổng quan và động cơ nghiên cứu

Bài báo đề xuất U-Net, một kiến trúc mạng nơ-ron tích chập dành cho phân đoạn ảnh y sinh. Khác với phân loại ảnh chỉ tạo một nhãn cho toàn ảnh, phân đoạn yêu cầu gán nhãn cho từng pixel để xác định vị trí và hình dạng cấu trúc cần quan tâm.

Tác giả xuất phát từ thực tế các bài toán ảnh y sinh thường thiếu ảnh đã được chuyên gia gán nhãn. Các phương pháp CNN dạng sliding-window phải chạy mạng riêng trên nhiều patch chồng lấn, gây dư thừa tính toán và chậm. Ngoài ra, kích thước patch tạo ra đánh đổi giữa lượng ngữ cảnh và độ chính xác định vị.

Mục tiêu của U-Net là kết hợp khả năng thu thập ngữ cảnh với khả năng định vị pixel chính xác trong một mạng fully convolutional, đồng thời khai thác data augmentation để học hiệu quả từ số lượng ảnh gán nhãn nhỏ.

2. Phương pháp đề xuất

2.1. Ý tưởng chính

U-Net gồm contracting path để thu nhận ngữ cảnh và expansive path đối xứng để khôi phục độ phân giải. Đặc trưng có độ phân giải cao từ contracting path được kết hợp với đặc trưng đã upsample ở expansive path. Nhờ đó, mô hình vừa sử dụng ngữ cảnh ở tầng sâu, vừa giữ thông tin không gian để định vị biên.

Expansive path cũng duy trì số lượng kênh đặc trưng tương đối lớn, cho phép truyền thông tin ngữ cảnh trở lại các tầng có độ phân giải cao. Kiến trúc không sử dụng fully connected layers.

2.2. Kiến trúc U-Net

- Contracting path: lặp lại hai phép tích chập 3×3 không padding; mỗi phép theo sau bởi ReLU. Sau đó max pooling 2×2, stride 2 thực hiện downsampling. Số kênh đặc trưng tăng gấp đôi tại mỗi bước downsampling.
- Expansive path: upsample feature map, sau đó áp dụng up-convolution 2×2 để giảm một nửa số kênh. Feature map tương ứng từ contracting path được crop rồi concatenate với feature map ở nhánh mở rộng. Tiếp theo là hai phép tích chập 3×3, mỗi phép theo sau bởi ReLU.
- Lớp đầu ra: phép tích chập 1×1 ánh xạ vector đặc trưng 64 chiều tại mỗi pixel thành số lớp cần phân đoạn.

- Kiến trúc gốc có 23 lớp tích chập. Crop feature map ở nhánh thu hẹp là cần thiết vì các phép tích chập không padding làm mất pixel ở đường biên.

Do chỉ sử dụng phần hợp lệ (valid part) của phép tích chập, bản đồ phân đoạn đầu ra nhỏ hơn ảnh đầu vào. Để phân đoạn ảnh lớn liền mạch, tác giả đề xuất overlap-tile strategy: chia ảnh thành các tile có vùng chồng lấn phù hợp; tại biên ảnh, ngữ cảnh thiếu được ngoại suy bằng cách phản chiếu (mirroring) ảnh đầu vào. Chiến lược này cũng giúp tránh giới hạn kích thước ảnh bởi bộ nhớ GPU.

2.3. Hàm mất mát

Mạng sử dụng pixel-wise Softmax trên feature map cuối cùng kết hợp cross-entropy loss có trọng số. Softmax chuyển activation thành xác suất thuộc từng lớp tại mỗi pixel; cross-entropy phạt dự đoán khi xác suất của lớp đúng thấp.

Weight map w(x) được đưa vào để tăng tầm quan trọng của một số pixel: (i) bù khác biệt tần suất pixel giữa các lớp; (ii) buộc mạng học các đường biên phân tách nhỏ giữa những tế bào cùng lớp đang tiếp xúc.

Công thức trong bài báo: $w(x) = wc(x) + w0 \cdot \exp(-(d1(x) + d2(x))^2 / (2\sigma^2))$. Trong đó wc(x) cân bằng tần suất lớp; d1(x) là khoảng cách đến biên tế bào gần nhất; d2(x) là khoảng cách đến biên tế bào gần thứ hai. Tác giả đặt $w0 = 10$ và σ xấp xỉ 5 pixel.

Lưu ý: loss gốc là pixel-wise Softmax kết hợp weighted cross-entropy; bài báo không sử dụng Dice Loss làm hàm mất mát chính.

2.4. Chiến lược huấn luyện và khởi tạo

- Huấn luyện bằng stochastic gradient descent (SGD) trong framework Caffe.
- Do phép tích chập không padding làm đầu ra nhỏ hơn đầu vào, tác giả ưu tiên tile đầu vào lớn để tận dụng bộ nhớ GPU và đặt batch size bằng một ảnh.
- Momentum được đặt ở mức 0.99 để cập nhật hiện tại chịu ảnh hưởng của nhiều mẫu huấn luyện đã quan sát trước đó.
- Khởi tạo trọng số để feature map có phương sai xấp xỉ đơn vị; sử dụng phân phối Gaussian với độ lệch chuẩn $\sqrt{(2/N)}$, trong đó N là số node đầu vào của một neuron.

2.5. Data augmentation

Data augmentation được xem là thiết yếu để học tính bất biến và độ bền vững khi chỉ có ít ảnh gán nhãn. Với ảnh hiển vi, các biến thiên cần xử lý gồm dịch chuyển, xoay, biến dạng và thay đổi giá trị mức xám.

- Elastic deformation: lấy các vector dịch chuyển ngẫu nhiên trên lưới thô 3×3 để tạo biến dạng trơn.
- Vector dịch chuyển được lấy mẫu từ phân phối Gaussian có độ lệch chuẩn 10 pixel; dịch chuyển tại từng pixel được tính bằng nội suy bicubic.

- Dropout ở cuối contracting path tạo hiệu ứng regularization và được tác giả mô tả như một dạng data augmentation ngầm.

Theo lập luận của bài báo, biến dạng đàn hồi đặc biệt hữu ích trong ảnh y sinh vì biến dạng mô là dạng biến thiên phổ biến và có thể được mô phỏng thực tế.

3. Thực nghiệm và kết quả

3.1. EM Segmentation Challenge

Nhiệm vụ đầu tiên là phân đoạn cấu trúc thần kinh trong ảnh hiển vi điện tử. Bộ dữ liệu gồm 30 ảnh 512×512 từ serial-section transmission electron microscopy của ventral nerve cord ở ấu trùng ruồi giấm giai đoạn đầu. Tập huấn luyện có ground-truth gán nhãn đầy đủ cho tế bào và màng; nhãn tập kiểm tra được giữ bí mật.

Ban tổ chức đánh giá bằng warping error, Rand error và pixel error. U-Net sử dụng kết quả trung bình trên 7 phiên bản xoay của dữ liệu đầu vào và không cần tiền xử lý hay hậu xử lý bổ sung trong kết quả được báo cáo.

Phương pháp	Warping error	Rand error	Pixel error
U-Net	0.000353	0.0382	0.0611
DIVE-SCI	0.000355	0.0305	0.0584
IDSIA (Ciresan et al.)	0.000420	0.0504	0.0613

U-Net đạt warping error 0.0003529 và Rand error 0.0382, tốt hơn kết quả sliding-window tốt nhất của Ciresan et al. là 0.000420 và 0.0504 tương ứng. Bảng xếp hạng ngày 6/3/2015 cho thấy U-Net đứng thứ nhất theo warping error.

3.2. ISBI Cell Tracking Challenge

Tác giả đánh giá phân đoạn tế bào trên hai bộ ảnh hiển vi ánh sáng truyền qua:

- PhC-U373: ảnh tế bào Glioblastoma-astrocytoma U373 trên nền polyacrylamide, thu nhận bằng phase-contrast microscopy; có 35 ảnh huấn luyện được gán nhãn một phần.
- DIC-HeLa: ảnh tế bào HeLa trên bề mặt kính phẳng, thu nhận bằng differential interference contrast (DIC) microscopy; có 20 ảnh huấn luyện được gán nhãn một phần.

Chỉ số đánh giá là Intersection over Union (IoU). Kết quả trong bảng của bài báo:

Phương pháp	PhC-U373 IoU	DIC-HeLa IoU
KTH-SE (2014)	0.7953	0.4607
Second-best 2015	0.83	0.46
U-Net (2015)	0.9203	0.7756

U-Net đạt IoU 0.9203 trên PhC-U373, cao hơn mức 0.83 của phương pháp đứng thứ hai. Trên DIC-HeLa, U-Net đạt 0.7756, so với 0.46 của phương pháp đứng thứ hai.

3.3. Nhận xét tổng hợp

- U-Net cho kết quả tốt trên ba nhiệm vụ phân đoạn khác nhau, bao gồm ảnh hiển vi điện tử và ảnh hiển vi ánh sáng.
- Mô hình học từ số lượng ảnh huấn luyện nhỏ: 30 ảnh trong thí nghiệm EM, 35 ảnh PhC-U373 và 20 ảnh DIC-HeLa.
- Các kết quả minh họa hiệu quả của kiến trúc contracting–expansive, skip connections, weighted loss và elastic deformation augmentation trong bối cảnh bài báo.
- Tác giả báo cáo thời gian huấn luyện khoảng 10 giờ trên GPU NVIDIA Titan 6GB; phân đoạn ảnh 512×512 mất dưới một giây trên GPU đời mới tại thời điểm công bố.

4. Kết luận của công trình

U-Net là kiến trúc phân đoạn ảnh y sinh có hiệu quả với số lượng ảnh gán nhãn hạn chế. Đóng góp cốt lõi là kiến trúc contracting–expansive đối xứng, kết hợp đặc trưng độ phân giải cao qua skip connections, cùng chiến lược tăng cường dữ liệu bằng biến dạng đàn hồi.

Weighted cross-entropy giúp nhấn mạnh pixel tạo ranh giới phân tách giữa những tế bào tiếp xúc. Thực nghiệm trên EM Segmentation Challenge và ISBI Cell Tracking Challenge 2015 cho thấy phương pháp hoạt động tốt trên nhiều loại ảnh y sinh.

5. Liên hệ với hướng nghiên cứu phân đoạn bệnh da

U-Net là nền tảng kiến trúc phù hợp để tham khảo khi phát triển mô hình phân đoạn tổn thương da, chẳng hạn biến thể nhẹ như Mobile Hybrid U-Net. Những ý tưởng có thể kế thừa gồm encoder–decoder, skip connections để bảo toàn thông tin vị trí và augmentation để tăng đa dạng dữ liệu.

Cần phân biệt điều kiện của bài báo gốc với quy trình dùng SAM ViT-B tạo pseudo-mask cho ảnh bệnh da. Trong bài báo U-Net, mô hình được huấn luyện và đánh giá trên ground-truth segmentation do con người gán nhãn. Pseudo-mask do SAM tạo ra là nhãn giả, không thể mặc nhiên xem là nhãn chuyên gia.

Nếu U-Net/Mobile Hybrid U-Net được đánh giá bằng chính pseudo-mask SAM, Dice và IoU chủ yếu đo mức độ phù hợp giữa dự đoán mô hình và nhãn giả. Các chỉ số đó không tự chứng minh vùng tổn thương được phân đoạn đúng thực tế. Để đánh giá khách quan, nên có một tập con ảnh với mask được chuyên gia kiểm tra hoặc gán nhãn thủ công và dùng làm ground truth độc lập.